

RAPPORT DE PROJET : STEP BY STEP SMART

Vulgarisation de l'Apprentissage par Renforcement Profond

Équipe : Groupe SMART 2026

Institution : INSA Lyon

Lien Projet : <https://github.com/r0n434/BladeWalker.git>

1. Introduction : La Philosophie de l'Apprentissage par l'Action

Le projet A.R.M SMART se définit comme un pont entre les mathématiques abstraites des algorithmes d'Intelligence Artificielle et la visualisation des concepts. Là où les équations d'optimisation par descente de gradient peuvent sembler opaques pour le grand public, la simulation leur donne un corps: celui du bras robotique R.E.X. ou du bipède BladeWalker.

L'analogie du vivant

L'entraînement de l'IA est ici comparable à l'apprentissage moteur d'un enfant [L'agent ne possède aucune connaissance innée; il explore son environnement par tâtonnement. À chaque essai, il commet des erreurs, mais lorsqu'un mouvement produit un succès, il ajuste sa stratégie interne pour le reproduire et l'optimiser.

Le cycle du Reinforcement Learning

Cette démarche repose sur le concept des Processus de Décision Markoviens (MDP), matérialisé par le cycle du Reinforcement Learning:

- Observation: L'IA analyse l'état actuel (angles des joints, vitesses, position de la cible).
- Action: Elle décide d'un mouvement via un espace d'actions continu (force appliquée aux moteurs).
- Récompense: L'environnement renvoie un signal (positif ou négatif) permettant de calculer l'erreur temporelle et d'ajuster les poids du réseau neuronal .

2. Objectifs et Attentes du Projet

L'objectif premier n'est pas uniquement de construire une IA performante, mais d'en vulgariser le fonctionnement auprès d'un public non-informaticien via une interface vulgarisée et visuelle.

- Interfacer un modèle d'IA avec un moteur de simulation physique.
- Entraîner le modèle sur des tâches de locomotion ou de manipulation.
- Construire un tableau de bord pédagogique pour visualiser l'évolution .

3. Architecture Technique et Environnements

Stack Logicielle

Composant	Technologie
Langage	Python
Apprentissage	Deep Reinforcement Learning (PPO, SAC)
Simulation	Gymnasium / Box2D
Interface	Application Web full-stack

Les Environnements de Simulation

Le projet s'appuie sur trois environnements distincts permettant de tester la robustesse des algorithmes:

- Niveau 1: Zone de Départ (R.E.X. Basic) - Apprentissage des coordonnées de base.
- Niveau 2: Transporteur - Bras articulé capable de récupérer et déplacer un objet.
- Niveau 3: Maîtrise Parfaite (BladeWalker) - Locomotion bipède complexe.

4. Analyse des Algorithmes : PPO vs SAC

Deux algorithmes majeurs ont été implémentés pour gérer les espaces d'actions continus :

Proximal Policy Optimization (PPO)

PPO est privilégié pour sa stabilité. Il évite les mises à jour de politique trop agressives grâce à une fonction d'objectif écrêtée (clipping), ce qui assure une progression constante sans effondrements de performance.

Soft Actor-Critic (SAC)

SAC introduit la notion d'entropie maximale. L'agent ne cherche pas seulement la récompense la plus élevée, mais aussi à agir de la manière la plus aléatoire possible (exploration). Cela favorise la créativité et la découverte de solutions plus robustes.

NEAT

Contrairement à PPO et SAC qui entraînent un cerveau figé, NEAT fait littéralement pousser l'intelligence du robot. C'est un algorithme évolutif qui ne règle pas seulement les poids, mais fait muter la structure même du réseau de neurones au fil des générations.

Complexification automatique : Il part d'un réseau minimal et ajoute des neurones selon les besoins du bras robotique.

Spéciation : Il protège les innovations structurelles fragiles (nouvelles articulations ou connexions) pour leur laisser le temps de devenir performantes.

Symbiose : faire évoluer la morphologie du bras (longueur, segments) et son contrôle neuronal en parfaite harmonie.

5. Le Dashboard Pédagogique

Le cœur de la vulgarisation réside dans une interface Web fluide et esthétique . Le visiteur navigue sur une 'carte de progression' le guidant de la Zone de Départ jusqu'à la Maîtrise Parfaite.

Sur le tableau de bord, l'utilisateur manipule des Sliders interactifs pour ajuster la fonction de récompense:

- Pénalité d'énergie: Force l'IA à économiser les mouvements parasites.
- Pénalité de tremblement: Pénalise les changements de direction brusques, lissant ainsi le mouvement.

6. Résultats, Bilan et Perspectives

Bilan de l'Apprentissage

Les résultats obtenus valident la démarche initiale. L'entraînement, monitoré via TensorBoard, montre que le modèle sort du comportement chaotique des 10 000 premiers steps pour atteindre une marche stable (ou un transport fluide) aux alentours des 500 000 steps . Les comportements dégénérés (robot qui rampe, bras qui tremble) ont été corrigés via l'optimisation fine des rewards .

Perspectives : Domain Randomization

L'étape suivante est l'intégration du Domain Randomization. En variant aléatoirement les constantes physiques (taille des segments de R.E.X., gravité, friction) pendant l'entraînement, le réseau de neurones apprendra à généraliser . L'objectif final est de créer un 'cerveau universel' capable d'être transféré sur un véritable robot physique .

Conclusion

En conclusion, le projet SMART réussit le pari de rendre l'IA tangible. En se concentrant sur l'évolution de l'apprentissage plutôt que sur le seul résultat final, il permet une compréhension profonde des mécanismes de l'intelligence artificielle pour un public élargi, ouvrant la voie à une IA responsable et comprise .